


TEMA 3

1. Introducción a la Inferencia Estadística

¿QUÉ VAMOS A VER HOY?

Aplicar las técnicas de Muestreo e
Inferencia Estadística



- Técnicas de muestreo
 - Estimar medias
 - Estimar proporciones
- Determinar el tamaño de una muestra

El Método Científico y la Estadística Inferencial



1- A partir de observaciones sobre un suceso, planteamos una **Hipótesis** sobre una **población**

2- **Diseño Experimental:** Decidir que datos (**variables**) se van a recoger sobre los individuos elegidos para el estudio (**muestra**)

3- **Recogida de datos:** estratificada o sistemática

4- Describir los datos obtenidos (**Estadística Descriptiva**)

5- Realizar una conclusión o "**Inferencia**" sobre la población

6- Cuantificar la "**Confianza**" en la inferencia.

ESTADÍSTICA INFERENCIAL

Al hacer estadística inferencial debemos enfrentarnos con dos problemas:




1.- Elección de la Muestra (**Muestreo**)

2.- Extrapolación de los resultados al resto de la Población
(**Inferencia**)

A- **Estimación** (puntual o por intervalos de confianza)


B- Contraste de Hipótesis

Población vs Muestra



POBLACION: También llamado "universo", es el **conjunto de individuos** u objetos de referencia sobre los cuales se realizan las **observaciones** y se plantean **hipótesis** y estamos interesados en obtener **conclusiones** (hacer inferencia).

- Cumplen características de asociación determinadas (p.ej demográficas).
- Pueden ser **finitas o infinitas**
- *Normalmente es demasiado grande para poder abarcarlo.*



Población vs Muestra

INDIVIDUO: Un individuo, objeto o **unidad de estudio**, a nivel estadístico, es **cada uno de los elementos** que componen a la población

MUESTRA: subconjunto de individuos, objetos o unidades estadísticas elegidos mediante **muestreo**, garantizando que sea representativo de la población.


- Sobre la muestra se realizan las observaciones (recopilación datos).
- Son **finitas** y de tamaño menor a la población.

- Esta formado por miembros "seleccionados" (individuos, unidades experimentales).

¿Qué es el Muestreo?

El **muestreo** es un conjunto de técnicas estadísticas utilizadas para la extracción de muestras de la población de referencia.

El muestreo debe garantizar que las características de la población se mantienen intactas en la muestra y **los resultados obtenidos sobre la muestra pueden utilizarse para realizar inferencias sobre la población**



Ventajas del Muestreo

- **Coste Reducido:** la recogida y tratamiento de datos resulta más barata al trabajar con una pequeña parte de la población.
- **Mayor Rapidez:** nos permite poder evaluar más rápido el resultado final
- **Mayores Posibilidades:** nos permite hacer determinado tipo de estudios en los cuales se destruyen las muestras tomadas

Importancia del Muestreo

La población ideal que se **pretende estudiar** se denomina
“población objetivo”

- No es fácil estudiar la población objetivo al completo. Aproximamos mediante **muestras** en las que cada individuo, idealmente, tiene la misma probabilidad de ser elegido.

- Tampoco es fácil elegir muestras de la población objetivo. P.ej. Si llamamos por teléfono excluimos a los que no tienen; si elegimos individuos en la calle, olvidamos los que están trabajando; etc.

El grupo que en realidad **podemos estudiar** se denomina
“población de estudio”

Sesgo en el Muestreo

- En ocasiones, las **poblaciones objetivo** y la **población de estudio** pueden diferir en cuanto a las variables que estudiamos
 - El nivel económico en la población de estudio mayor que en la objetivo
 - Los individuos se eligen en la calle pueden ser de mayor edad (mas jubilados)
- En este caso, diremos que las muestras que se elijan estarán **"sesgadas"**.
- Al tipo de sesgo debido a **diferencias sistemáticas** entre población objetivo y población de estudio se denomina **"sesgo de selección"**
- Hay otras fuentes de error/sesgo (independientes del muestreo)
 - No responder a encuestas embarazosas; mentir en las preguntas; etc
- Para evitar este tipo de sesgo se utiliza la **técnica de respuesta aleatorizada**

Técnicas de Muestreo

Cuando elegimos individuos de una población de estudio para formar muestras podemos encontrarnos en las siguientes situaciones:

- **Muestreos probabilistas**: Conocemos la probabilidad de que un individuo sea elegido para la muestra.
- **Muestreos no probabilistas**: No se conoce la probabilidad. Son muestreos que seguramente esconden sesgos.

Tipos de Muestreo

Muestreo Aleatorio Simple

Muestreo Sistemático


Muestreo Estratificado

Muestreo por Conglomerados

Tipos de Muestreo

Muestreo Aleatorio Simple (m.a.s)

Todos los elementos tienen la **misma probabilidad** de ser incluidos en la muestra.



- **Sin reposición** (sin reemplazamiento): no se permite que un mismo individuo sea seleccionado más de una vez
- **Con reposición** (con reemplazamiento): un elemento puede ser extraído varias veces


Tipos de Muestreo

Muestreo Sistemático

Se tiene una lista de los individuos de la población de estudio.

Si queremos una muestra de un tamaño dado, elegimos individuos igualmente espaciados de la lista, donde el primero ha sido elegido al azar.

!!! Si en la lista existen periodicidades, obtendremos una muestra sesgada.




Tipos de Muestreo

Muestreo Estratificado

Se aplica cuando sabemos que hay ciertos **factores** (variables, subpoblaciones o estratos) **que pueden influir en el estudio** y queremos asegurarnos de tener cierta cantidad mínima de individuos de cada tipo (Hombres y mujeres, jóvenes, adultos y ancianos, etc)

Se realiza entonces un **m.a.s.** de los individuos de cada uno de los **estratos**. Al extrapolar los resultados a la población hay que tener en cuenta el **tamaño relativo del estrato con respecto al total** de la población.



Tipos de Muestreo

Muestreo Estratificado

EJEMPLO 1: *Efecto de un antidepresivo en la población*

ESTRATOS: Niños, adultos, ancianos

EJEMPLO 2: *Cantidad de coches de alta gama en una ciudad*


ESTRATOS: Población de barrios clase alta, media, baja, etc.

Tipos de Muestreo

Muestreo por Conglomerados

Se aplica cuando es difícil tener una lista de todos **los individuos** que forman parte de la población de estudio, pero sin embargo sabemos que **se encuentran agrupados naturalmente en grupos**.

Se realiza eligiendo varios de esos grupos al azar, y ya elegidos algunos podemos estudiar a todos los individuos de los grupos elegidos o bien seguir aplicando dentro de ellos más muestreos por grupos, por estratos, aleatorios simples,...



Tipos de Muestreo

Muestreo por Conglomerados

EJEMPLO

- *Conocer la cantidad de ejercicio físico que se realiza en España,*
Podemos dividir a la población en regiones, comarcas, ciudades, barrios.
Esto serían **conglomerados** (divisiones naturales de la población).

Al igual que en el muestreo estratificado, al extrapolar los resultados a la población hay que **tener en cuenta el tamaño relativo de unos grupos con respecto a otros.**

2. Estimación Estadística

2. Estimación Estadística

2.A- Estimación

Un **estimador** es una cantidad numérica calculada sobre una muestra y que esperamos que sea una buena **aproximación** de cierta cantidad con el mismo significado en la población (**parámetro**).

1. **Estimación Puntual:** Obtener un pronóstico numérico **único** sobre un parámetro de la distribución de la variable.
2. **Estimación por Intervalos de Confianza:** Obtener un margen de variación para un parámetro de la distribución.

⌘ Población (parámetro)	⌘ Muestra (estimador)
--------------------------------	------------------------------

- Proporción P
- Media μ
- Varianza σ^2

- Proporción p
- Media $\bar{X}$
- Cuasivarianza $\hat{S}^2$

Objetivo: $\min(\vartheta - \hat{\vartheta})$

2.A.1.- Estimación Puntual

Características deseables:

- **Consistencia:** Cuando el tamaño de la muestra crece arbitrariamente, el valor estimado se aproxima al parámetro desconocido (mayor precisión).
- **Carencia de sesgo (error):** El valor medio que se obtiene de la estimación para diferentes muestras debe ser el valor del parámetro (reproducibilidad).
- **Eficiencia:** Al estimador, al ser v.a., no puede exigírsele que para una muestra cualquiera se obtenga como estimación el valor exacto del parámetro. Sin embargo podemos pedirle que su dispersión con respecto al valor central (varianza) sea tan pequeña como sea posible.
- **Suficiencia:** El estimador debería aprovechar toda la información existente en la muestra.

Estimación Puntual de la media o de la Varianza

Población (parámetro)

- Proporción p
- Media μ
- Varianza σ^2

$$X_1, X_2, \dots, X_n, \quad \begin{cases} E[X_i] = \mu \\ \text{Var}[X_i] = \sigma^2 \end{cases}$$

Muestra (estimador)

- Proporción p
- Media $\bar{X}$

$$\bar{X} = \frac{1}{n}(X_1 + X_2 + \dots + X_n)$$

- **Cuasivarianza**

$$\hat{S}^2 = \frac{n}{n-1} S^2$$

➤ **Estimación Puntual sin sesgo**, verifica: El valor medio que se obtiene de la estimación para diferentes muestras debe ser el valor del parámetro.

$$E[\bar{X}] = \mu$$

$$\text{Var}[\bar{X}] = \frac{\sigma^2}{n}$$


2.A.2.- Estimación por Intervalos de Confianza

Se denomina **estimación por intervalos de confianza** para un **nivel de confianza $(1-\alpha)*100\%$** dado, a un intervalo que ha sido construido de tal manera que con una frecuencia: $1 - \alpha$, **realmente** contiene al parámetro.

- Es decir, la **probabilidad de error** (no contener al parámetro) es α .
 - α También se llama **nivel de significación**.
 - Valores típicos de $\alpha = 0,10 ; 0,05 ; 0,01$ (fijado por el investigador)
- En general el tamaño del intervalo **disminuye con el tamaño muestral** y **aumenta con el nivel de confianza**
- En todo intervalo de confianza hay una noticia buena y otra mala:
 - La buena: hemos usado una técnica que en % alto de casos acierta.
 - La mala: **no sabemos con certeza** si ha acertado en nuestro caso.


Según el teorema del Límite Central

Histograma de la población



La media de toda
la población es μ

Histograma de la medias



La dispersión de las medias
es más pequeña es el

ERROR ESTÁNDAR

$$SE = \frac{\sigma}{\sqrt{n}}$$

μ La media de las medias es
la misma que la población

supongamos que nos piden calcular entre qué dos variables se encuentra el 80% de una determinada muestra (nivel de confianza)



α ó nivel de significación $(100\% - 80\%) = 20\%$

Se sabe que el peso de los recién nacidos sigue una distribución normal

Si en una muestra aleatoria simple de 25 de ellos se obtiene una media muestral de 3,00 kg y una desviación típica de 0,50 kg. Calcular un intervalo de confianza para la media poblacional que presente una confianza del 95%.

3. Intervalos de Confianza (medias y proporciones)

3. Intervalos de Confianza (medias y proporciones)

Estimación por Intervalos de Confianza

Intervalos de Confianza para la Distribución Normal

1. **Intervalo de Confianza para la Media con Varianza σ^2 Conocida:** *No es un caso práctico* ya que es imposible conocer sin conocer previamente μ .
2. **Intervalo de Confianza para la Media μ (caso general):** *Caso con interés práctico.* Nos permite estimar el intervalo de confianza para μ a partir de los resultados de la muestra.
3. **Intervalo de Confianza para una Proporción p :** *Otro caso de interés práctico.* Permite establecer el intervalo de confianza para la proporción a partir de las frecuencias relativas de las observaciones
4. **Estimación del Tamaño Muestral:** Permite decidir el tamaño muestral para obtener intervalos de confianza para la media o para proporciones con una precisión y significación establecida de antemano.

1. Intervalo de Confianza para la media (μ) con varianza (σ^2) conocida


- Aplicando el Teorema del límite Central, todo estimador ($\bar{X}$) tiende a presentar una distribución Normal con un **error típico** asociado

$$\bar{X} \rightsquigarrow N\left(\mu, \frac{\sigma^2}{n}\right)$$

- Utilizaremos los valores ya tabulados
- Para ello tipificamos según:

$$Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \rightsquigarrow N(0,1)$$

TABLA



$$x_{\alpha/2} = \bar{X} - z_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

$$x_{1-\alpha/2} = \bar{X} + z_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

$$\mu = \bar{X} \pm z_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

1. Intervalo de Confianza para la media (μ) con varianza (σ^2) conocida

$$\mu = \bar{X} \pm z_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

EJEMPLO

Se sabe que el peso de los recién nacidos sigue una distribución normal con una desviación típica de 0,75 kg.

Si en una muestra aleatoria simple de 25 de ellos se obtiene una media muestral de 3,00 kg y una desviación típica de 0,50 kg. Calcular un intervalo de confianza para la media poblacional que presente una confianza del 95%.

$$N=25$$

$$\sigma=0,75$$

$$\bar{X}=3,00\text{kg}$$

$$S= 0,50\text{kg}$$

$$1-\alpha=0,95$$

$$\alpha/2=0,025$$

Intervalo de Confianza para μ (caso general)

1º Determinar la $Z_{1-\alpha/2}$ sabiendo que $\alpha/2=0,025$

$$Z = 1,960$$

2º Estimar el intervalo de confianza de la media poblacional

$$\mu = \bar{X} \pm z_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

$$\mu = 3.00 \pm (1.960 * 0.75/\sqrt{25})$$

$$\mu = 3.00 \pm 0.294$$


$$\mu = [2.706 ; 3.294]$$

Table 1(a) continued


z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1.3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9278	0.9292	0.9306	0.9319
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.8	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767
2.0	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2.1	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850	0.9854	0.9857
2.2	0.9861	0.9864	0.9868	0.9871	0.9875	0.9878	0.9881	0.9884	0.9887	0.9890
2.3	0.9893	0.9896	0.9898	0.9901	0.9904	0.9906	0.9909	0.9911	0.9913	0.9916
2.4	0.9918	0.9920	0.9922	0.9925	0.9927	0.9929	0.9931	0.9932	0.9934	0.9936
2.5	0.9938	0.9940	0.9941	0.9943	0.9945	0.9946	0.9948	0.9949	0.9951	0.9952
2.6	0.9953	0.9955	0.9956	0.9957	0.9959	0.9960	0.9961	0.9962	0.9963	0.9964
2.7	0.9965	0.9966	0.9967	0.9968	0.9969	0.9970	0.9971	0.9972	0.9973	0.9974
2.8	0.9974	0.9975	0.9976	0.9977	0.9977	0.9978	0.9979	0.9979	0.9980	0.9981
2.9	0.9981	0.9982	0.9982	0.9983	0.9984	0.9984	0.9985	0.9985	0.9986	0.9986
3.0	0.9987	0.9987	0.9987	0.9988	0.9988	0.9989	0.9989	0.9989	0.9990	0.9990
3.1	0.9990	0.9991	0.9991	0.9991	0.9992	0.9992	0.9992	0.9992	0.9993	0.9993
3.2	0.9993	0.9993	0.9994	0.9994	0.9994	0.9994	0.9994	0.9995	0.9995	0.9995
3.3	0.9995	0.9995	0.9995	0.9996	0.9996	0.9996	0.9996	0.9996	0.9996	0.9997
3.4	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9998

2. Intervalo de Confianza para la media (μ) con varianza (σ^2) desconocida

TABLES



- Utilizaremos la **cuasidesviación típica** ($\hat{S}$) como estimador de σ
- Utilizaremos la distribución de **t-Student** ($n-1$)



$$\mu = \bar{X} \pm t_{n-1, 1-\alpha/2} \cdot \frac{\hat{S}}{\sqrt{n}}$$

Table 2 Critical values of the t-distribution

ν	Level of significance α				
	0.10	0.05	0.025	0.01	0.005
1	3.078	6.314	12.706	31.821	63.657
2	1.886	2.920	4.303	6.965	9.925
3	1.638	2.353	3.182	4.541	5.841
4	1.533	2.132	2.776	3.747	4.604
5	1.476	2.015	2.571	3.365	4.032
6	1.440	1.943	2.447	3.143	3.707
7	1.415	1.895	2.365	2.998	3.499
8	1.397	1.860	2.306	2.896	3.355
9	1.383	1.833	2.262	2.821	3.250
10	1.372	1.812	2.228	2.764	3.169
11	1.363	1.796	2.201	2.718	3.106
12	1.356	1.782	2.179	2.681	3.055
13	1.350	1.771	2.160	2.650	3.012
14	1.345	1.761	2.145	2.624	2.977
15	1.341	1.753	2.131	2.602	2.947
16	1.337	1.746	2.120	2.583	2.921
17	1.333	1.740	2.110	2.567	2.898
18	1.330	1.734	2.101	2.552	2.878
19	1.328	1.729	2.093	2.539	2.861
20	1.325	1.725	2.086	2.528	2.845
21	1.323	1.721	2.080	2.518	2.831
22	1.321	1.717	2.074	2.508	2.819
23	1.319	1.714	2.069	2.500	2.807
24	1.318	1.711	2.064	2.492	2.797
25	1.316	1.708	2.060	2.485	2.787
26	1.315	1.706	2.056	2.479	2.779
27	1.314	1.703	2.052	2.473	2.771
28	1.313	1.701	2.048	2.467	2.763
29	1.311	1.699	2.045	2.462	2.756
30	1.310	1.697	2.042	2.457	2.750
∞	1.282	1.645	1.960	2.326	2.576

2. Intervalo de Confianza para la media (μ) con varianza (σ^2) desconocida

$$\mu = \bar{X} \pm t_{n-1, 1-\alpha/2} \cdot \frac{\hat{S}}{\sqrt{n}}$$

EJEMPLO

Se sabe que el peso de los recién nacidos sigue una **distribución normal**. Si en una muestra aleatoria simple de 25 de ellos se obtiene una media muestral de 3,00 kg y una desviación típica de 0,50 kg. **Calcular un intervalo de confianza para la media poblacional que presente una confianza del 95%.**

$$\begin{aligned} N &= 25 \\ \bar{X} &= 3,00 \text{ kg} \\ S &= 0,50 \text{ kg} \end{aligned}$$

$$\begin{aligned} 1-\alpha &= 0,95 \\ \alpha/2 &= 0,025 \end{aligned}$$

Intervalo de Confianza para μ con varianza desconocida

1º Calcular raíz de la cuasivarianza

$$\hat{S}^2 = \frac{n}{n-1} S^2 = (25/24) \cdot 0,5^2; \hat{S} = 0,51$$

2º Determinar la t-Student para
 $v=n-1=24$; $\alpha/2=0,025$

$$t = 2,064$$

2º Estimar el intervalo de confianza de la media poblacional

$$\mu = \bar{X} \pm t_{n-1, 1-\alpha/2} \cdot \frac{\hat{S}}{\sqrt{n}}$$

$$\mu = 3,00 \pm 0,21 \quad \text{ó} \quad \mu = [2,79 - 3,21]$$




Table 2 Critical values of the t-distribution

v	Level of significance α				
	0.10	0.05	0.025	0.01	0.005
1	3.078	6.314	12.706	31.821	63.657
2	1.886	2.920	4.303	6.965	9.925
3	1.638	2.353	3.182	4.541	5.841
4	1.533	2.132	2.776	3.747	4.604
5	1.476	2.015	2.571	3.365	4.032
6	1.440	1.943	2.447	3.143	3.707
7	1.415	1.895	2.365	2.998	3.499
8	1.397	1.860	2.306	2.896	3.355
9	1.383	1.833	2.262	2.821	3.250
10	1.372	1.812	2.228	2.764	3.169
11	1.363	1.796	2.201	2.718	3.106
12	1.356	1.782	2.179	2.681	3.055
13	1.350	1.771	2.160	2.650	3.012
14	1.345	1.761	2.145	2.624	2.977
15	1.341	1.753	2.131	2.602	2.947
16	1.337	1.746	2.120	2.583	2.921
17	1.333	1.740	2.110	2.567	2.898
18	1.330	1.734	2.101	2.552	2.878
19	1.328	1.729	2.093	2.539	2.861
20	1.325	1.725	2.086	2.528	2.845
21	1.323	1.721	2.080	2.518	2.831
22	1.321	1.717	2.074	2.508	2.819
23	1.319	1.714	2.069	2.500	2.807
24	1.318	1.711	2.064	2.492	2.797
25	1.316	1.708	2.060	2.485	2.787
26	1.315	1.706	2.056	2.479	2.779
27	1.314	1.703	2.052	2.473	2.771
28	1.313	1.701	2.048	2.467	2.763
29	1.311	1.699	2.045	2.462	2.756
30	1.310	1.697	2.042	2.457	2.750
∞	1.282	1.645	1.960	2.326	2.576

3-Intervalos de confianza para una proporción (p)

La proporción estimada se puede calcular a partir de una distribución Normal $N(p, pq/n)$ con parámetros **p** (proporción) y **pq/n** (varianza).


$$\hat{p} = \frac{X}{n} \approx N\left(p, \frac{pq}{n}\right)$$

$p = \text{prob. éxito}$
 $q = \text{prob. fracaso} = 1-p$

Si tipificamos, el valor de la proporción (Z) estaremos en una distribución Normal $N(0,1)$.

$$\frac{\hat{p} - p}{\sqrt{\frac{\hat{p}\hat{q}}{n}}} \approx Z \sim N(0, 1)$$

$$p = \hat{p} \pm z_{1-\alpha/2} \sqrt{\frac{\hat{p}\hat{q}}{n}} \text{ con una confianza de } 1 - \alpha$$



Intervalos para una Proporción

EJEMPLO

Se desea estimar el resultado de un referéndum mediante un sondeo. Para ello se realiza un muestreo aleatorio simple con $n = 100$ personas y se obtiene que 35 votarán a favor y 65 votarán en contra. Calcule un intervalo de confianza para el verdadero resultado del referéndum con un nivel de significación del 5%.

$$\begin{aligned}n &= 100 \\ p &= 35/100 \\ q &= 1-p = 65/100\end{aligned}$$

$$\begin{aligned}\alpha &= 0,05 \\ \alpha/2 &= 0,025\end{aligned}$$

Intervalos para una Proporción

EJEMPLO

- El parámetro a estimar en un intervalo de confianza al 95% ($\alpha=0,05$) es p .
- Vamos a suponer que p es la probabilidad de **votar a favor**.

$$p = \hat{p} \pm Z_{1-\alpha/2} \sqrt{\frac{\hat{p}\hat{q}}{n}}$$

$$\hat{p} = \frac{35}{100} = 0,35 \rightarrow \hat{q} = 1 - \hat{p} = 0,65$$

$$p = 0,35 \pm 1,96 \sqrt{\frac{0,35 * 0,65}{100}}$$

$$p = 0,35 \pm 0,0935$$

*El error cometido en la estimación de la proporción es aprox. del 9%
Para reducirlo, sólo podemos aumentar el tamaño de la muestra.*

4- Estimación del Tamaño Muestral (N)

Antes de realizar un estudio de inferencia estadística sobre una variable, lo primero es **decidir el número de elementos, n, a elegir en la muestra aleatoria.**

Para ello consideraremos que el estudio se basará en una variable de **distribución normal**, y nos interesa obtener para un nivel de significación α dado, una precisión (error máximo que nos podemos permitir) **d ó error**.

Si n es suficientemente grande, la distribución t de Student se aproxima a la distribución normal. Luego, una manera de obtener la precisión buscada consiste en **elegir n con los siguientes criterios:**

Estimación de media μ

$$n \geq \frac{z_{1-\alpha/2}^2 \hat{S}^2}{d^2}$$

Estimación de proporción p

$$N \geq \hat{p}\hat{q} \frac{z_{1-\alpha/2}^2}{\text{error}^2}$$

Estimación del Tamaño Muestral

EJEMPLO

Para el ejemplo anterior, calcule de que tamaño debería haber sido la muestra para tener un error máximo del 1% (error $d=0,01$).


$$N \geq \hat{p}\hat{q} \frac{z_{1-\alpha/2}^2}{\text{error}^2}$$

$$N \geq \frac{(0,35 \cdot 0,65 \cdot 1,96^2)}{(0,01)^2} = 8740$$



ESTADÍSTICA

CLASE PRACTICA 11 (I)



Ejercicio 1.

Una conocida marca de bicicletas quiere saber la opinión de los ciclistas profesionales que utilizan sus modelos XTR16 y XTR17. Para dicho propósito encarga a una empresa de demoscopia que realice el sondeo. La empresa entrevista al azar a 1000 ciclistas europeos, pertenecientes a equipos federados profesionales y les pide que evalúen en una escala de 0 a 10 en qué medida volverían a utilizar dichos modelos de bicicleta en la siguiente temporada (siendo 0 un "NO" con total seguridad y 10 un "SI, volveré a utilizar las bicicletas de su marca). Se obtuvo como resultado una media de 4,5 y una cuasi desviación típica de 2,7. ¿Entre qué valores se encontrará la media de todos los ciclistas europeos para niveles de confianza del:

- a) 95%
- b) 99%?

Ejercicio 2.

$$n=40$$

$$\bar{X}=123$$

$$s^2=644$$

En una muestra de 40 atletas se mide el ritmo cardiaco antes de comenzar una carrera importante, obteniéndose un valor medio de 123 p.p.m, con una varianza de 47 p.p.m.

- ¿Entre qué valores se hallará el verdadero ritmo cardiaco promedio para la población de atletas con un nivel de confianza del 90%?
- ¿Y con una confianza del 95%?
- ¿Qué hubiese pasado si la muestra hubiera sido de 20?

a) $\alpha/2 = 0.05 \rightarrow t_{39, 0.05} = 1.645$ $\mu = (123 \pm 1.8) = (121.2, 124.8) \leftarrow 90\%$ $A=3$

b) $\alpha/2 = 0.025 \rightarrow t_{39, 0.025} = 1.96$ $\mu = (123 \pm 2.5) = (120.5, 125.5) \leftarrow 95\%$ $A=5$

c) $\alpha/2 = 0.05 \rightarrow t_{19, 0.05} = 1.729$ $\mu = 123 \pm 2.72 = (120.28, 125.72) \leftarrow$

$\hat{s}^2=7.03$ $\alpha/2 = 0.025 \rightarrow t_{19, 0.025} = 2.093$ $\mu = 123 \pm 3.29 = (119.71, 126.29)$

¿error?

- Para = N.C
 - $\uparrow n$ Disminuye el intervalo (menor Amplitud)
 - $\downarrow n$ Aumenta el intervalo (mayor Amplitud)
- Para = n
 - $\uparrow NC$ Mayor Amplitud
 - $\downarrow NC$ menor amplitud.

Ejercicio 3.

Para la obtención de un certificado de calidad, una empresa productora de bañadores de natación debe demostrar que el número de bañadores defectuosos que llega al mercado no excede el 5%. Para ello se ha elegido al azar una muestra de 200 piezas del lote de la última semana y se han contabilizado 14 piezas con algún defecto de fabricación.

¿Entre qué valores se encuentra la proporción de piezas defectuosas producidas en la última semana? Considere un nivel de significación de 0,05.

Ejercicio 4.

A la misma muestra de atletas del Ejercicio 2 ($n = 40$ atletas) se le preguntó si utilizaban alguna técnica de relajación previa a la carrera, siendo 18 los que contestaron afirmativamente. Obtenga el IC de la proporción de atletas de la población que utiliza alguna técnica de relajación antes de carreras importantes para un nivel de confianza del 95%.

Ejercicio 5.

Determine de que tamaño debía haber sido la muestra del Ejercicio 2 para alcanzar una precisión de 1,5 p.p.m.

ESTADISTICA

TEMA 3

3. Intervalos de Confianza **(Diferencias de medias y proporciones** **o inferencias sobre diferencias)**

Estimación por Intervalos de Confianza

Intervalos de Confianza para Variables Normales

Intervalo de Confianza para la Diferencia de Medias de Poblaciones Independientes : Permite estimar un intervalo de confianza para la diferencia de medias de dos poblaciones a partir de las medias de las muestras y de las variancias de dichas poblaciones.

Con Varianzas Conocidas

- **Intervalo de Confianza para la Diferencia de Proporciones:** Permite estimar un intervalo de confianza para la diferencia de proporciones de dos poblaciones a partir de las proporciones de las muestras.

Estimación por Intervalos de Confianza

Intervalos de Confianza para la Distribución Normal

Intervalo de Confianza para la Diferencia de Medias de Poblaciones Independientes : Permite estimar un intervalo de confianza para la diferencia de medias de dos poblaciones a partir de las medias de las muestras y de las variancias de dichas poblaciones.

Varianzas Conocidas

$$\left[\hat{X} - \hat{Y} - Z_{1-\frac{\alpha}{2}} \sqrt{\frac{\sigma_x^2}{N} + \frac{\sigma_y^2}{M}} ; \hat{X} - \hat{Y} + Z_{1-\frac{\alpha}{2}} \sqrt{\frac{\sigma_x^2}{N} + \frac{\sigma_y^2}{M}} \right]$$

Si 0 pertenece al intervalo, las medias son iguales

Intervalo de Confianza para la Diferencia de Medias de Poblaciones Independientes: Varianzas Conocidas

EJEMPLO

Se quiere determinar un intervalo de confianza al 90% para la diferencia de tiempo diario de utilización de dos impresoras en una empresa. Para ello se controló el tiempo, en horas, de funcionamiento de ambas impresoras en una serie de días elegidos al azar, y se obtuvieron los siguientes resultados:

IMPRESORA X	3.2	2.1	2.7	3.4	1.9	4.2	3.8	2.6	5.2	4
IMPRESORA Y	3.4	3.3	2.5	4.6	2.8	3.6	4.3			

Supuesto que el tiempo de utilización de cada impresora sigue una distribución normal, determinar el intervalo de confianza deseado suponiendo que las varianzas de cada una de las dos impresoras son $V_x = 1.1$ y $V_y = 0.7$.

Intervalo de Confianza para la Diferencia de Medias de Poblaciones Independientes: Varianzas Conocidas

EJEMPLO

$$\left[\hat{\bar{X}} - \hat{\bar{Y}} - Z_{1-\frac{\alpha}{2}} \sqrt{\frac{\sigma_x^2}{N} + \frac{\sigma_y^2}{M}} ; \hat{\bar{X}} - \hat{\bar{Y}} + Z_{1-\frac{\alpha}{2}} \sqrt{\frac{\sigma_x^2}{N} + \frac{\sigma_y^2}{M}} \right]$$

IMPRESORA X	3.2	2.1	2.7	3.4	1.9	4.2	3.8	2.6	5.2	4
IMPRESORA Y	3.4	3.3	2.5	4.6	2.8	3.6	4.3			

$$\sigma_x^2 = 1,1 \quad \bar{X} = 33,1/10 = 3,31$$

$$\sigma_y^2 = 0,7 \quad \bar{Y} = 24,5/6 = 4,08$$

$$1 - \alpha = 0,9 \quad (\text{Amplitud del intervalo de confianza; } \alpha/2=0,05; 1-0,05=0,95; Z_{(1-\alpha/2)}=1,645)$$

SOLUCION: [-1,55 ; 0,01]

Como el 0 pertenece al intervalo de confianza, se puede afirmar con un 90% de seguridad que **no existen diferencias entre las medias**

Estimación por Intervalos de Confianza

Intervalos de Confianza para la Distribución Normal

Intervalo de Confianza para la Diferencia de Medias de Poblaciones Independientes : Permite estimar un intervalo de confianza para la diferencia de medias de dos poblaciones a partir de las medias de las muestras y de las variancias de dichas poblaciones.

- **Intervalo de Confianza para la Diferencia de Proporciones:** Permite estimar un intervalo de confianza para la diferencia de proporciones de dos poblaciones a partir de las proporciones de las muestras.

$$\left[\begin{array}{c} \widehat{P}_1 - \widehat{P}_2 - Z_{1-\frac{\alpha}{2}} \sqrt{\frac{\widehat{P}_1(1 - \widehat{P}_1)}{N} + \frac{\widehat{P}_2(1 - \widehat{P}_2)}{M}} \\ ; \\ \widehat{P}_1 - \widehat{P}_2 + Z_{1-\frac{\alpha}{2}} \sqrt{\frac{\widehat{P}_1(1 - \widehat{P}_1)}{N} + \frac{\widehat{P}_2(1 - \widehat{P}_2)}{M}} \end{array} \right]$$

Si 0 pertenece al intervalo, las proporciones son iguales

Intervalo de Confianza para la Diferencia de Proporciones

Realizamos un ensayo clínico para estudiar la efectividad de dos nuevos medicamentos (M.1 y M.2) sobre una muestra de pacientes diagnosticados de depresión. El porcentaje de pacientes cuyos síntomas mejoran tras ser tratados con el medicamento M.1 es del 31% ($n=200$), y el porcentaje de pacientes cuyos síntomas mejoran tras ser tratados con el medicamento M.2 es del 10,8% ($m=350$).

Calcule un intervalo de confianza ($\alpha=0.05$) para la diferencia de proporciones de pacientes de la población cuyos síntomas mejoran tras ser tratados con ambos medicamentos.

$$\left[\begin{array}{c} \widehat{P}_1 - \widehat{P}_2 - Z_{1-\frac{\alpha}{2}} \sqrt{\frac{\widehat{P}_1(1-\widehat{P}_1)}{N} + \frac{\widehat{P}_2(1-\widehat{P}_2)}{M}} \\ ; \\ \widehat{P}_1 - \widehat{P}_2 + Z_{1-\frac{\alpha}{2}} \sqrt{\frac{\widehat{P}_1(1-\widehat{P}_1)}{N} + \frac{\widehat{P}_2(1-\widehat{P}_2)}{M}} \end{array} \right]$$

$$P_1=0,31$$

$$Q_1=1-P_1=0,69$$

$$P_2=0,108$$

$$Q_2=1-P_2=0,992$$

$$P_1-P_2=0,31-0,108=0,202$$

$$\alpha/2=0,025$$

$$Z(1-0,025)=Z(0,975)= 1,96$$

Intervalo de Confianza para la Diferencia de Proporciones

Realizamos un ensayo clínico para estudiar la efectividad de dos nuevos medicamentos (M.1 y M.2) sobre una muestra de pacientes diagnosticados de depresión. El porcentaje de pacientes cuyos síntomas mejoran tras ser tratados con el medicamento M.1 es del 31% ($n=200$), y el porcentaje de pacientes cuyos síntomas mejoran tras ser tratados con el medicamento M.2 es del 10,8% ($m=350$).

Calcule un intervalo de confianza ($\alpha=0.05$) para la diferencia de proporciones de pacientes de la población cuyos síntomas mejoran tras ser tratados con ambos medicamentos.

$$\left[\begin{array}{c} \widehat{P}_1 - \widehat{P}_2 - Z_{1-\frac{\alpha}{2}} \sqrt{\frac{\widehat{P}_1(1-\widehat{P}_1)}{N} + \frac{\widehat{P}_2(1-\widehat{P}_2)}{M}} \\ ; \\ \widehat{P}_1 - \widehat{P}_2 + Z_{1-\frac{\alpha}{2}} \sqrt{\frac{\widehat{P}_1(1-\widehat{P}_1)}{N} + \frac{\widehat{P}_2(1-\widehat{P}_2)}{M}} \end{array} \right]$$

$$P_1=0,31$$

$$Q_1=1-P_1=0,69$$

$$P_2=0,108$$

$$Q_2=1-P_2=0,992$$

$$P_1-P_2=0,31-0,108=0,202$$

$$\alpha/2=0,025$$

$$Z(1-0,025)=Z(0,975)= 1,96$$

SOL: $[0,202 \pm 0,0723]$ (las prop. son diferentes)

ESTADÍSTICA

CLASE PRACTICA 11 (II)

Ejercicio 1.

Según los resultados del CIS de Abril de 2020, el Partido Popular obtendría el 14,8% de los votos (sobre una muestra de 3279 personas). Según una encuesta similar realizada por el DYM sobre 1000 personas, el Partido Popular obtendría el 22,4% de los votos. Calcule un intervalo de confianza para la diferencia de proporciones para un nivel de significación del 1%. ¿Se puede afirmar que los resultados son iguales?

Ejercicio 2.

El 71,1% de los 121 alumnos que se presentaron al primer examen de estadística aprobó el examen mientras que el segundo examen fue aprobado por el 52,9% de los 119 que se presentaron.

- a) Calcule el intervalo de confianza para la diferencia de proporciones de los alumnos que han aprobado ambos exámenes para un nivel de significación $\alpha=0,05$.
- b) ¿Se puede afirmar que los resultados son diferentes? Justifique su respuesta.

Ejercicio 3.

Se conoce que la varianza en el número de minutos de resistencia al agua de los Samsung Galaxy S20 en el control de calidad es de 121. Por otro lado, se conoce la varianza en el número de Samsung Z Flip defectuosos es de 49. Se realiza un ensayo sobre 40 Galaxy S20 y sobre 50 Z Flip dando una media de resistencia al agua de 38 y 32 minutos y una desviación típica de 10 y 8 minutos respectivamente. Calcule un intervalo de confianza para la diferencia media de resistencia. ¿Ambos teléfonos resisten lo mismo?. Justifique